Modele oparte na drzewach

Drzewa decyzyjne, lasy losowe, boosting

Labratorium 6

Sebastian Kuzara

KRUK S.A.

Statistical Methods Development Area

Wrocław, 2024

Drzewa decyzyjne

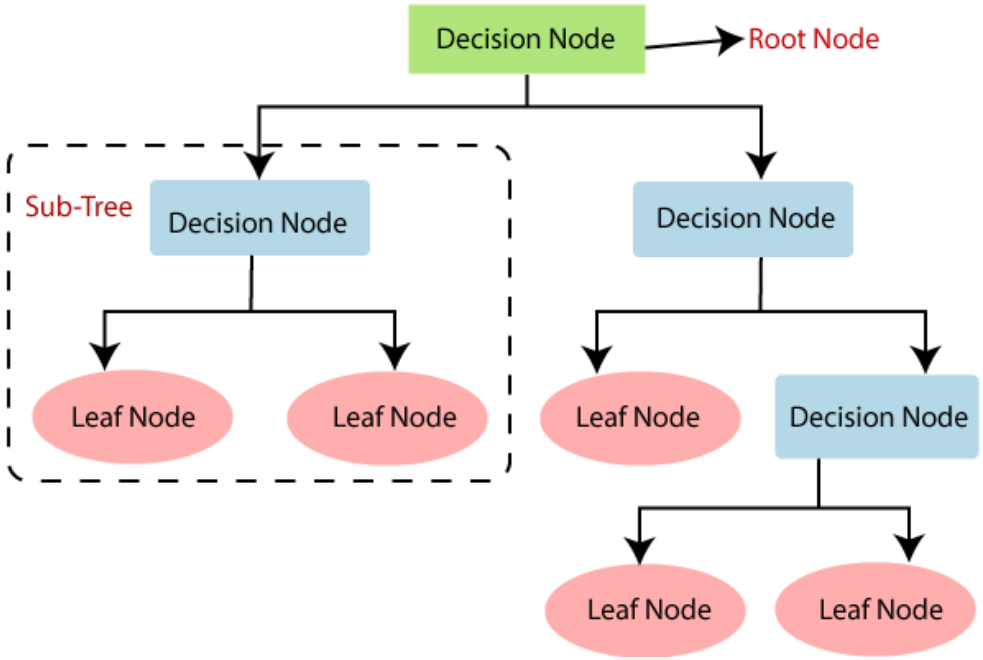

https://www.javatpoint.com/machine-learning-decision-tree-classification-algorithm

Podział na podstawie:

- Gini index dla modelu klasyfikacyjnego
- RMSE w modelu regresyjnym

Dodatkowy tutorial: https://www.analyticsvidhya.com/blog/2021/08/decision-tree-algorithm/

Drzewa decyzyjne - hiperparametry


```
rpart::rpart.control(
# Podstawowe:
            minsplit = 20, # minimalna liczba obserwacji w węźle
            minbucket = round(minsplit/3), # minimalna liczba obserwacji w węźle-liściu
            cp = 0.01, # o ile min. ma się poprawić metryka podziału (Gini/RMSE), aby do tego podziału doszło
            maxdepth = 30, # maksymalna głębokość drzewa (gdzie root=0), maksylmalna liczba poziomów podziału

# Pozostałe:
            maxcompete = 4,
            maxsurrogate = 5,
            usesurrogate = 2,
             xval = 10,
            surrogatestyle = 0, ...)
```

Przykładowe wywołanie modelu drzewa losowego w R:

```
model_tree <- rpart::rpart(
             formula = Gender~.,
            data=cases,
            method="class",
            control=rpart.control(minsplit = 1000, cp=0.0001)
)
```

Lasy losowe

- przykład ensemble model - predykcje poprzez głosowanie wielu modeli
- Bagging

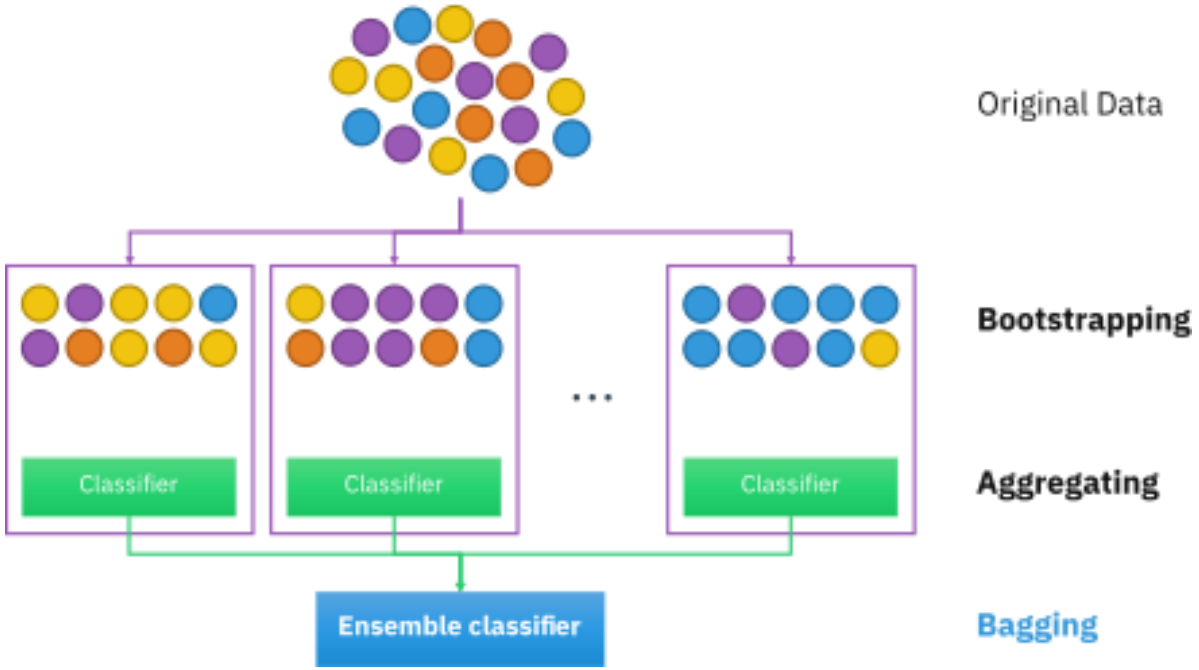

https://www.analyticsvidhya.com/blog/2021/06/understanding-random-forest/

Lasy losowe- hiperparametry


```
library(randomForest)

# Podstawowe HP:
## ntree=500 - liczba submodeli drzew losowych
## mtry - liczba cech jaka ma być wylosowana do pojedynczego modelu drzewa decyzyjnego
## sampsize - liczba obserwacji jaka ma być losowana do modelu drzewa decyzyjnego
## nodesize - minimalna wielkość węzła-liścia w modelu drzewa (odpowiednik minbucket w rpart)
## maxnodes - maksymalna liczba węzłów liści


rf <- randomForest(
        formula=TOA~.,
        data=cases,
        nodesize=1000,
        ntrees=500,
        maxnodes=2^6,
        na.action = "na.omit")
```

Boosting

- AdaBoost (tylko klasyfikacja)
- GBM
- LightGBM
- XGBoost

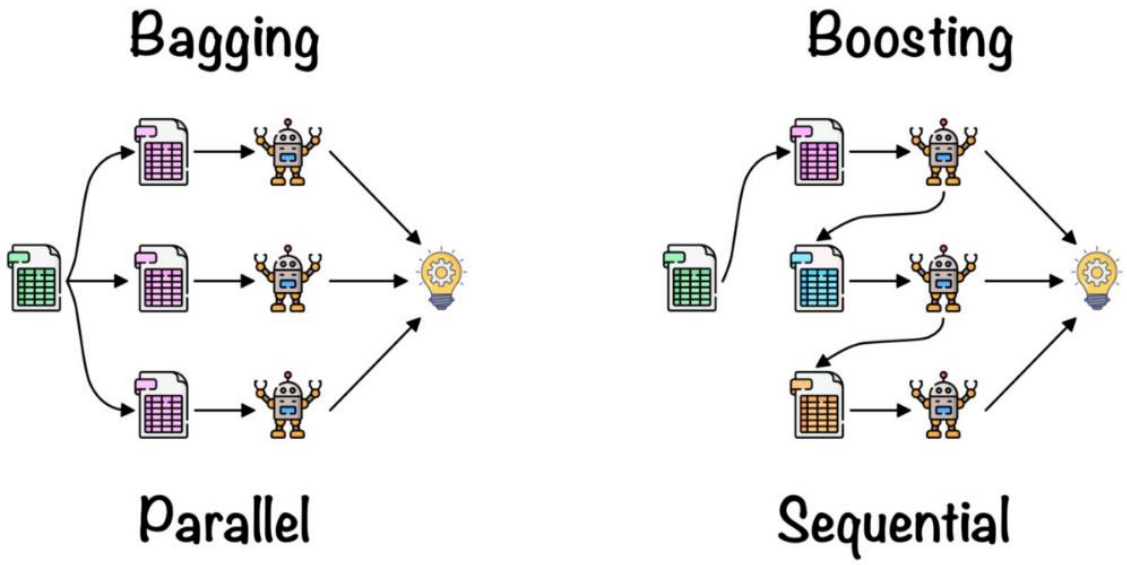

https://www.analyticsvidhya.com/blog/2021/06/understanding-random-forest/

Dodatkowy materiał:
https://towardsdatascience.com/boosting-algorithms-explained-d38f56ef3f30

GBM - hiperparametry

```
library(gbm)

boost_model <- gbm(
             TOA~Age+Principal+MeanSalary+LastPaymentAmount,
            data=cases,
            distribution = "gaussian", # w zależności czy klasyfikacja czy regresja
            n.trees = 500, # liczba submodeli drzew
            interaction.depth = 6, # max głębokość 1 drzewa
            shrinkage = 0.01, # learning rate, "o ile kolejne modele wpływają na predykcje"
            n.minobsinnode = 1000, # min. liczba obserwacji w węźle-liściu
            bag.fraction = 0.5, # jaki % cech wylosować do pojedynczego submodelu drzewa )
```

Przykładowe postępowanie przy optymalizacji HP:

1. ustalamy “mała” liczbę drzew i stosunkowo “duży” learning rate
2. sprawdzamy różne kombinacje głębokości, minimalnej liczby obserwacji w liściach oraz % cech w submodelu
3. dla najlepszej (najlepszych) kombinacji z punktu 2. testujemy różne warianty liczby drzew i learning rate
4. wybieramy wartości, kiedy model przestaje się istotnie poprawiać na zbiorze walidacyjnym

Metody optymalizacji hiperparametrów

- grid search
- random search
- optymalizacja bayesowska (przykładowa implementacja: rBayesianOptimization)